

KnowFlow 企业可信知识协作Agent

面向中小型企业的权限感知型 RAG + KnowledgeOps 企业知识助手

作者：胡梦圆

版本：V2.0

日期：2026.04

实现方式：Dify POC → 自研 FastAPI + Hybrid RAG + RBAC + Eval/Tracing + Docker 部署

核心原则：不是“再做一个企业聊天机器人”，而是做一个可评测、可治理、可追责的企业知识可信系统。

一、文档概述

1.1 文档信息

字段	内容
产品名称	KnowFlow 企业可信知识协作 Agent
版本	V2.0
产品定位	面向企业内部知识查找、流程答疑与知识治理的可信 AI 助手
产品形态	员工问答端 + 管理端 + 评测与可观测平台
目标组织规模	100—3000 人企业，优先适配客服、交付、研发、HR、行政等知识密集部门
核心用户	普通员工 / 服务交付岗 / 新员工 / 知识管理员 / 部门负责人
核心价值	让员工获得“可验证、可追溯、权限正确、版本正确”的答案，并把 Badcase 自动转化为知识治理任务
核心差异化	权限感知检索、版本感知检索、证据链回答、置信度分流、知识缺口自动治理、离线评测与在线可观测
产品阶段	可演示 MVP → 可部署 Demo → 可量化评测版本

1.2 名词解释

名词	解释
RAG	Retrieval-Augmented Generation。先检索企业知识，再基于检索证据生成答案。
Hybrid Retrieval	向量语义检索与 BM25/关键词检索并行召回，再通过 Reranker 重排。
Permission-aware RAG	检索前根据用户身份、部门、角色过滤候选文档，避免模型在生成阶段才“补做权限控制”。
Version-aware RAG	检索时识别文档生效状态、版本号、有效期，默认只回答当前有效版本，冲突时显式提示。
Evidence Chain	答案中的关键结论必须能映射到具体文档、版本、段落或页码。
Confidence Gating	根据检索质量、证据完整度和生成结果，将回答分为直接回答、补充确认、拒答/转人工。
KnowledgeOps	通过 Badcase、热点问题、低命中问题、过期知识等信号推动知识库持续治理。
Eval	面向检索、生成、引用、拒答、时延与成本建立离线评测与回归测试机制。

二、项目背景与目标

2.1 项目背景

企业内部知识库项目已经从“能回答”进入“能否可信落地”的竞争阶段。传统知识库问答的主要问题不再只是资料分散，而是答案是否命中正确版本、是否越权、是否能解释来源、遇到证据不足时是否会主动降级，以及系统能否通过 Badcase 持续变好。

- 信息分散：制度、SOP、FAQ、产品文档分布在云盘、IM、Wiki、邮件和个人文件中。
- 版本冲突：旧制度与新制度同时被检索到，普通 RAG 容易基于过期文档生成“看似正确”的答案。
- 权限风险：企业知识天然存在部门/角色边界，单纯在前端隐藏文档并不能阻止检索越权。
- 答案可信度不足：员工看到答案却无法快速判断“依据是什么、是否为最新、能不能用于决策”。
- 维护成本高：管理员依赖人工发现知识缺口，低质量问答无法反哺知识库。
- 评测缺失：很多 POC 只有 Demo，没有检索、生成、引用、拒答、时延和成本的量化指标。

2.2 产品目标

--	--

目标	V2.0 目标值 / 说明
查找效率	典型知识问答首答 P95 $\leq$ 5 秒；员工从搜索到获得可用答案的平均时间显著低于人工查找
检索质量	Recall@5 $\geq$ 85%，MRR@10 $\geq$ 0.70（基于内部金标评测集）
答案可信	关键事实引用覆盖率 $\geq$ 95%；引用文档版本正确率 100%
拒答能力	知识库外/证据不足问题不强答；高风险场景进入澄清或转人工
权限安全	未授权文档在召回阶段即过滤；越权检索测试通过率 100%
知识治理	自动发现低命中问题、热点问题、过期/冲突知识，并形成管理员待办
工程可观测	对每次问答记录 query、召回文档、rerank 分数、模型输出、时延、token 与反馈

2.3 非目标（V2.0 不做什么）

- 不做通用互联网搜索助手。
- 不替代企业 OA/ERP/CRM 作为主业务系统。
- 不在没有可靠证据时替用户做审批、财务、法务等高风险决策。
- V2.0 不追求多 Agent 炫技，优先保证单 Agent/RAG 链路的可控、可评测和可复现。
- 不以模型微调作为第一优化手段，优先通过数据治理、检索策略、Prompt 与评测闭环优化。

三、用户画像与核心场景

用户	核心任务	主要痛点	V2.0 价值
普通员工 / 新员工	查制度、流程、SOP、产品资料	找不到、找错版本、不会组织关键词	自然语言提问 + 当前有效版本 + 引用证据 + 追问
客服 / 交付	高频答疑、查产品规则	重复问题多、口径不一致	标准答案优先 + 高置信快速回答 + 可复制引用
知识管理员	上传、更新、下线、维护 FAQ	不知道哪里缺知识、维护靠人工	KnowledgeOps 待办 + 冲突/过期预警 + FAQ 候选
部门负责人	关注知识利用与服务质量	无法衡量知识库效果	命中率、Badcase、知识缺口、部门使用率与趋势看板

3.1 核心用户故事

1. 作为新员工，我希望直接问“差旅报销需要哪些材料”，并看到答案来自哪份制度、哪个版本、哪一段。
2. 作为客服，我希望询问产品规则时优先得到管理员维护的标准答案；若只有文档证据，也要给出来源。
3. 作为普通员工，当我无权访问某文档时，希望系统告诉我“存在相关知识但无权限”，并一键发起权限申请，而不是泄露内容。
4. 作为知识管理员，我希望系统自动列出近 7 天低命中问题、重复提问和冲突文档，告诉我下一步该补什么知识。
5. 作为负责人，我希望知道回答准确率、拒答率、引用覆盖率、用户反馈、平均时延和单问成本，以判断系统是否值得继续投入。

四、产品定位与差异化策略

4.1 定位

KnowFlow 不定位为“企业版 ChatGPT”，而定位为“企业知识可信层 + KnowledgeOps 闭环”。用户端解决“能否快速得到可验证答案”，管理端解决“知识如何持续变新、变准、变可控”。

4.2 差异化能力

能力	普通知识库 Demo	KnowFlow V2.0
检索	单向量召回	BM25 + Embedding 混合召回 + Rerank + Query Rewrite
权限	前端隐藏/生成后过滤	检索前 ACL/Metadata Filter，授权边界进入召回逻辑
版本	按相似度命中	生效/失效/版本号/有效期参与检索，默认最新有效版
答案	直接生成	证据链 + 句级引用 + 证据不足时澄清/拒答
风险	统一回答	置信度分流：高置信直答 / 中置信澄清 / 低置信拒答转人工
运营	看总问答量	Badcase 聚类、知识缺口、冲突文档、FAQ 候选、回归评测
工程	Dify 流程可跑	

	API 化、日志/Trace、离线 Eval、 Docker 化、可重复部署
--	---

4.3 核心产品决策

- 决策 1：不追求“什么都答”，把“答错”视为比“答不出”更严重的问题。
- 决策 2：权限控制放在检索层，而不是生成层；无权限内容不进入模型上下文。
- 决策 3：版本状态是检索条件，不只是后台展示字段；过期文档默认不可被问答命中。
- 决策 4：将答案质量拆成“检索是否找到、证据是否足够、生成是否忠实、引用是否完整”四层指标。
- 决策 5：Badcase 不是测试附件，而是 KnowledgeOps 的主输入；每个失败都应能进入可归因、可修复、可回归的闭环。

五、产品架构与技术架构

5.1 产品功能架构

端	一级模块	核心功能
员工端	可信问答	自然语言提问、多轮追问、证据引用、来源预览、答案反馈
员工端	权限与协作	无权限提示、权限申请、申请状态
管理端	知识管理	文档上传、解析状态、标签、版本、生效/失效、冲突检测
管理端	KnowledgeOps	Badcase 池、知识缺口、热点问题、FAQ 候选、过期知识提醒
管理端	评测中心	金标集、检索评测、生成评测、回归测试、版本对比
管理端	数据看板	使用、质量、性能、成本、反馈、知识健康度
系统层	治理与审计	RBAC/ACL、操作日志、Trace、模型与 Prompt 版本

5.2 技术架构（建议落地）

将 Dify 作为早期 POC/Prompt 实验工具，正式 Demo 将核心检索、权限、评测与日志能力迁出 Dify。

层	技术	职责
前端	Next.js / React + Ant Design	问答端、管理端、评测页、Trace 详情页
API	FastAPI	鉴权、问答 API、知识库 API、评测 API、权限申请 API
编排	LangGraph（可选）/ 自定义状态机	Query 分流、检索、置信度判断、回答、拒答、人工兜底
LLM	OpenAI-compatible API / Qwen / DeepSeek 等	Query Rewrite、答案生成、自动评测
Embedding	BGE-M3 或同级中英文模型	语义向量
Reranker	bge-reranker-v2-m3 或同级	对 Hybrid 召回候选重排
全文检索	Elasticsearch / OpenSearch	BM25、字段检索、版本/标签过滤
向量库	Qdrant 或 PostgreSQL + pgvector	向量召回与 metadata filter
业务库	PostgreSQL	用户、角色、文档、版本、权限、反馈、评测集
缓存/任务	Redis + Celery/RQ	缓存、文档异步解析、批量评测
可观测	Langfuse / OpenTelemetry	Trace、Prompt 版本、模型调用、token、延迟
部署	Docker Compose	一键部署全部服务，体现工程完整性

5.3 核心问答链路

- 6. 用户登录后携带 user_id / department / role / authorized_kb_ids。
- 7. Query Router 判断问题类型：事实问答、制度流程、文档定位、知识库外问题。
- 8. Query Rewrite 生成检索友好的查询，并抽取时间、部门、版本等过滤条件。
- 9. Permission Filter 先生成允许访问的文档范围。

- 10. Hybrid Retrieval：BM25 与向量检索并行召回 TopN。
- 11. Version Filter：过滤失效版本；同主题多版本时优先当前生效版本。
- 12. Reranker 对候选 chunk 重排。
- 13. Evidence Judge 判断证据完整度与冲突情况。
- 14. Confidence Gating：高置信直答；中置信要求澄清；低置信拒答或转人工。
- 15. LLM 基于允许证据生成结构化答案，并输出 citation_ids。
- 16. Response Assembler 将 citation_id 映射为文档名、版本、段落、页码。
- 17. 全链路写入 Trace，用户反馈进入 Badcase 池。

六、详细功能需求说明

6.1 员工端 - 可信智能问答

功能点	优先级	详细业务规则
自然语言问答	P0	支持口语化、多轮提问；只基于用户授权知识回答。
证据引用	P0	答案关键结论后展示引用编号；点击展开文档名、版本、生效时间、原文片段。
置信度分流	P0	高置信直接回答；中置信提示“我找到两种可能口径”并追问；低置信拒答。
版本提示	P0	若存在旧版与新版，默认使用当前有效版，并显示“已依据 Vx.x 生效版本回答”。
冲突提示	P0	若不同有效文档存在冲突，不自动合并结论，展示冲突并建议联系知识负责人。
无权限处理	P0	只告知“存在可能相关内容但当前无权限”，不暴露标题/片段等敏感信息；提供权限申请入口。
问题改写	P1	支持“换个说法”“只看财务制度”“给新人解释”等上下文指令。

答案反馈	P1	点赞/点踩 + 原因标签：答非所问、引用不对、版本过期、信息缺失、权限问题。
------	----	--

6.2 管理端 - 知识生命周期管理

功能点	优先级	详细业务规则
多格式上传	P0	支持 PDF/Word/PPT/TXT/Markdown； 异步解析并展示状态。
版本管理	P0	同一知识主题必须有 version_no、 effective_at、expired_at、 status；新版本发布可自动失效旧 版。
生效/失效	P0	失效知识不参与默认检索；管理员 可在调试页手动查询历史版本。
标签与元数据	P0	部门、业务域、文档类型、负责 人、保密级别、有效期均可作为检 索过滤字段。
冲突检测	P1	同主题多份有效知识出现高语义重 合且关键结论不一致时生成冲突任 务。
文档健康度	P1	展示更新时间、近30天命中量、低 反馈次数、待复核状态。
解析预览	P1	上传后查看 chunk、页码、标题层 级、表格解析结果，支持手工修正 元数据。

6.3 管理端 - 权限管理

功能点	优先级	详细业务规则
RBAC	P0	

		角色：超级管理员、知识管理员、普通员工。
ACL/Metadata 权限	P0	支持按知识库、部门、文档级授权；权限在召回前执行。
权限申请	P1	用户触发无权限场景时创建申请；管理员审批后权限实时生效。
审计日志	P1	记录权限新增/回收、文档发布/失效、管理员操作。

6.4 管理端 - KnowledgeOps

功能点	优先级	详细业务规则
Badcase 池	P0	自动收集低置信回答、点踩、拒答、引用缺失、冲突回答，并保留完整 Trace。
问题归因	P0	标签：检索未召回、召回不相关、版本错误、证据不足、生成幻觉、权限拦截、知识缺失。
知识缺口聚类	P1	对近7/30天拒答与低命中问题聚类，输出缺口主题、问题数、涉及部门。
FAQ 候选	P1	高频相似问题自动形成 FAQ 草稿，必须由管理员审核后发布。
过期知识提醒	P1	临近有效期或长期未更新但高频命中的文档进入待复核。
一键回归	P1	管理员修复知识或 Prompt 后，选择受影响 Badcase 一键重新评测。

6.5 评测中心

能力	指标	说明
----	----	----

检索评测	Recall@K / MRR / nDCG	判断正确证据能否被召回、排序是否靠前。
答案正确性	Answer Correctness	基于人工金标 + LLM Judge，关键样本人工复核。
忠实性	Faithfulness	答案是否只基于检索证据，不凭空扩展。
引用覆盖	Citation Coverage	关键事实是否都有对应引用。
引用正确	Citation Precision	引用是否真的支持对应结论。
拒答质量	No-answer Precision / Recall	知识库外问题是否正确拒答；有答案问题是否误拒。
权限安全	Unauthorized Retrieval Rate	未授权内容进入召回结果的比例，目标 0。
工程指标	P50/P95 Latency、Token、Cost	回答速度与成本优化。

七、关键流程与异常机制

7.1 置信度分流

等级	判定信号	用户表现
高置信	Top1/TopK 证据相关度高、无版本冲突、引用充分	直接回答 + 引用
中置信	存在多种可能口径、Query 模糊、关键条件缺失	先澄清问题或展示候选口径，不强行给唯一答案
低置信	无有效证据、检索分数低、知识库外问题	拒答 + 建议人工/补充信息

7.2 全局异常处理

异常	处理规则

知识库无匹配	明确说明未找到可靠依据；禁止模型用常识补答企业内部规则。
有效版本冲突	停止生成统一结论，展示冲突状态并进入管理员冲突任务。
权限不足	不返回敏感标题和片段；引导申请权限。
文档解析失败	文档不进入可检索状态；管理员端显示失败原因和重试。
Reranker/模型异常	降级为基础检索结果或返回稍后重试；记录 trace。
超时	超过阈值后返回降级答案或“正在处理”，不得无限等待。
Prompt Injection	系统指令优先；用户输入不得修改权限范围、系统 Prompt 或要求输出隐藏上下文。

八、数据指标体系

8.1 北极星指标

有效自助解决率（Self-service Resolution Rate）

定义：无需转人工、用户未点踩、且通过质量阈值的有效回答数 / 总有效提问数。

8.2 指标树

维度	核心指标
业务价值	有效自助解决率、单次知识查找耗时、重复答疑减少量
检索质量	Recall@5、MRR@10、Top1 相关率、版本命中正确率
生成质量	Correctness、Faithfulness、Citation Coverage、拒答准确率
用户体验	点赞率、点踩率、平均追问轮次、人工转接率
知识运营	缺口数、修复周期、过期文档数、冲突文档数、FAQ 采纳率

工程	P50/P95 时延、错误率、单问 token、单问成本
----	------------------------------

九、非功能性需求与验收标准

类别	验收标准
性能	典型问答 P95 $\leq$ 5s；文档检索 API P95 $\leq$ 1.5s；批量解析异步执行。
安全	越权召回率 0；权限变更可审计；敏感配置不写入前端。
可靠性	模型不可用时可降级；任务失败可重试；文档解析幂等。
可观测	每次请求有 trace_id，可查看召回、重排、Prompt、模型、时延、token。
可评测	至少 100 条金标问题，覆盖高频问答、无答案、权限、版本冲突、多轮等类型。
可部署	Docker Compose 一键启动 API、DB、向量库、Redis、前端与观察组件。
可维护	Prompt、模型、Embedding、Reranker 配置化；评测结果可按版本对比。

十、需求池与版本规划

版本	目标	范围
V2.0 MVP	从 Dify Demo 升级为可评测可信 RAG	Hybrid Retrieval、Rerank、引用、版本、ACL、置信度分流、基础 Eval、Trace
V2.1	形成 KnowledgeOps 闭环	Badcase 归因、缺口聚类、FAQ 候选、冲突/过期提醒、一键回归
V2.2	增加有限行动能力	权限申请 Tool、工单创建 Tool；Human-in-the-loop，不做高风险

		自动执行
V3.0	组织级知识 Agent	多知识域路由、跨系统工具、个性化上下文、成本优化与规模化治理

10.1 V2.0 P0 清单

- 用户登录与 RBAC/ACL
- 文档上传、解析、版本、生效/失效
- Hybrid Retrieval + Rerank
- 权限感知与版本感知检索
- 结构化答案 + 引用证据
- 置信度分流与拒答
- Badcase 记录
- 100 条金标评测集 + 检索/生成基础评测
- Trace 与延迟/token 记录
- Docker Compose 可部署 Demo